

特征值与特征向量，特征值计算

2025年3月17日 16:29

特征向量与特征空间

在机器学习中，数据通常以表格（或称矩阵）的形式表示。表格中的每一列称为特征（Feature），每一行称为数据点（Data Point）或样本（Sample）。特征向量是将这些特征组合在一起的向量，其中每个元素表示数据点的一个特征值。


对以下表格，有以下特征：

- 身高（Height）
- 体重（Weight）
- 年龄（Age）

对于张三，我们可以将这些特征值组合在一起，形成一个特征向量：

$$\mathbf{x}^{\rightarrow} = [\mathbf{x1}, \mathbf{x2}, \mathbf{x3}] = [1.80, 75, 25]$$

其中，x1 表示身高，x2 表示体重，x3表示年龄。



特征空间（Feature Space）是一个抽象的多维空间，其中每个维度对应于数据点的一个特征。特征空间的维数等于特征的数量。


在上面的例子中，我们三个特征，因此特征空间的维数为3。在这个空间中，我们可以将一个人表示为一个点：

$$\mathbf{p}^{\rightarrow} = [1.80, 75, 25]$$

这个点代表了这个人特征空间中的位置。

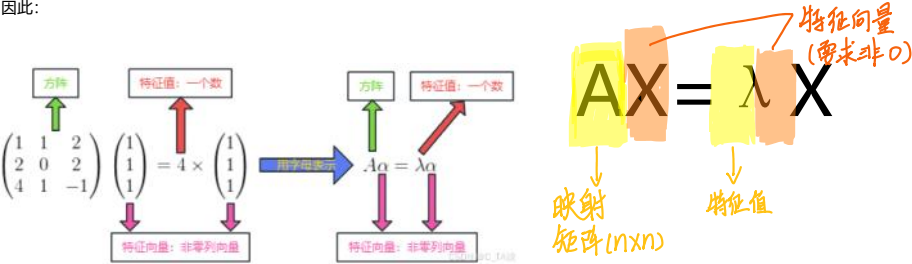
1.什么是特征值？

先从几何意义上理解：



向量x1经过矩阵A映射——>Ax1——>x1与Ax1不在一条直线上——>不构成特征向量

向量x2经过矩阵A映射——>Ax2——>x2与Ax2在一条直线上——>构成特征向量——>矩阵A只对x2起到了伸缩作用
因此：



注：

如果特征值是负数，那说明了矩阵不但把向量拉长（缩短）了，而且让向量指向了相反的方向。


λ

λ

y

正。


如果特征值是**负数**，那说明了矩阵不但把向量拉长（缩短）了，而且让向量指向了相反的方向。



【熟肉】线性代数的本质 - 10 - 特征向量与特征值 哔哩哔哩 bilibili

简而言之——>特征向量就是在线性变化当中**不变**的向量

在线性代数中，“特征”就是一种更抽象的描述。矩阵乘法对应了一个变换，是把任意一个向量变成另一个方向或长度都大多不同的新向量。在这个变换的过程中，原向量主要发生旋转、伸缩的变化。如果矩阵对某一个向量或某些向量只发生伸缩（尺度）变换，而**没有产生旋转**的效果（也就意味着张成的子空间没有发生改变），这样的向量就认为是特征向量。



在这个仿射变换中，蒙娜丽莎的图像被变形，但是中心的纵轴在变换下保持不变。（注意：角落在右边的图像中被裁掉了。）蓝色的向量，从胸部到肩膀，其方向改变了，但是红色的向量，从胸部到下巴，其方向不变。因此红色向量是该变换的一个特征向量，而蓝色的不是。**因为红色向量既没有被拉伸又没有被压缩，其特征值为1。所有沿着垂直线的向量也都是特征向量，它们的特征值相等。它们构成这个特征值的特征空间。**

2.特征值计算方法

$$A\alpha = \lambda\alpha \Rightarrow (\lambda E - A)\alpha = \theta,$$

即要求齐次线性方程组 $(\lambda E - A)x = \theta$ 有非零解，

即方程 $|\lambda E - A| = 0$ 的根就是矩阵 A 的特征值，

相应**非零解**即为特征向量。

例题:

设 $A = \begin{pmatrix} -2 & 1 & 1 \\ 0 & 2 & 0 \\ -4 & 1 & 3 \end{pmatrix}$, 求 A 的特征值与特征向量。

1、求特征方程 $|\lambda E - A| = 0$ 的全部根, 即为矩阵 A 的全部特征值;

$$|\lambda E - A| = \begin{vmatrix} \lambda + 2 & -1 & -1 \\ 0 & \lambda - 2 & 0 \\ 4 & -1 & \lambda - 3 \end{vmatrix}$$

$$= (\lambda - 2)^2(\lambda + 1) = 0,$$

所以 A 的特征值为 $\lambda_1 = 2$ (二重根), $\lambda_2 = -1$ 。

2、对每一特征值 λ_i , 求出齐次线性方程组

$$(\lambda_i E - A)x = 0$$

的一个基础解系 $\eta_1, \eta_2, \dots, \eta_{n-r}$, 其中 r 为 $\lambda_i E - A$ 的秩;

则 A 的属于特征值 λ_i 的全部特征向量为

$$k_1 \eta_1 + k_2 \eta_2 + \dots + k_{n-r} \eta_{n-r},$$

其中 k_1, k_2, \dots, k_{n-r} 为不全为零的任意数。

$$\text{对 } \lambda_1 = 2, 2E - A = \begin{pmatrix} 4 & -1 & -1 \\ 0 & 0 & 0 \\ 4 & -1 & -1 \end{pmatrix} \rightarrow \begin{pmatrix} 4 & -1 & -1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix},$$

相应齐次线性方程组的基础解系为

$$\alpha_1 = (1, 0, 4)^T, \quad \alpha_2 = (0, 1, -1)^T,$$

因此属于特征值 $\lambda_1 = 2$ 的全部特征向量为

$$k_1 \alpha_1 + k_2 \alpha_2 \quad (k_1, k_2 \text{ 不全为零});$$

$$\begin{aligned} &\rightarrow \text{降阶: } (\lambda - 2) \begin{vmatrix} \lambda + 2 & -1 \\ 4 & \lambda - 3 \end{vmatrix} \\ &= (\lambda - 2)[(\lambda + 2)(\lambda - 3) - 4] \\ &= (\lambda - 2)[\lambda^2 - \lambda + 2] \\ &= (\lambda - 2)^2(\lambda + 1) \end{aligned}$$

$$\text{对 } \lambda_2 = -1, -E - A = \begin{pmatrix} 1 & -1 & -1 \\ 0 & -3 & 0 \\ 4 & -1 & -4 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & -1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix},$$

相应齐次线性方程组的基础解系为

$$\alpha_3 = (1, 0, 1)^T,$$

因此属于特征值 $\lambda_2 = -1$ 的全部特征向量为 $k_3 \alpha_3 (k_3 \neq 0)$ 。

用python中的numpy库计算特征值与特征向量

代码:

```
import numpy as np
a = np.matrix('-2 1 1;0 2 0;-4 1 3')
b=np.linalg.eig(a)
print(b)
```

结果:

```
EigResult(eigenvalues=array([-1.,  2.,  2.]), eigenvectors=matrix([[[-0.70710678, -0.24253563,  0.30151134],
[ 0.,          0.,          0.90453403],
[-0.70710678, -0.9701425 ,  0.30151134]]]))
```

其中: 特征值EigResult(eigenvalues=array([-1., 2., 2.]

特征向量: eigenvectors=matrix

```
[[[-0.70710678, -0.24253563, 0.30151134],
[ 0.,          0.,          0.90453403],
[-0.70710678, -0.9701425 , 0.30151134]]])
```

numpy 计算出的特征向量是归一化的, 即每个特征向量的模长为 1

- 第一列特征向量的模长:

$$\sqrt{(-0.70710678)^2 + 0^2 + (-0.70710678)^2} = \sqrt{0.5 + 0 + 0.5} = \sqrt{1} = 1$$

- 第二列特征向量的模长:

$$\sqrt{(-0.24253563)^2 + 0^2 + (-0.9701425)^2} = \sqrt{0.0588 + 0 + 0.9412} = \sqrt{1} = 1$$

- 第三列特征向量的模长:

$$\sqrt{(0.30151134)^2 + (0.90453403)^2 + (0.30151134)^2} = \sqrt{0.0909 + 0.8182 + 0.0909} =$$

- 特征值 -1 对应的特征向量 $\begin{pmatrix} -0.70710678 \\ 0 \\ -0.70710678 \end{pmatrix}$ 可以表示为 $-\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$, 与手动计算的 $\begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$ 方向一致。

通过一个简单的线性回归示例来展示如何使用Python的scikit-learn库实现特征向量和特征空间的计算。

```
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
# 生成一组随机数据
np.random.seed(42)
X = np.random.rand(100, 2)
y = 3 * X[:, 0] + 2 * X[:, 1] + np.random.randn(100)
# 标准化特征向量
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

```
# 创建线性回归模型
model = LinearRegression()

# 训练模型
model.fit(X_scaled, y)

# 预测目标变量
y_pred = model.predict(X_scaled)

# 计算预测误差
error = np.mean((y_pred - y) ** 2)

print("预测误差:", error)

# 查看特征向量
print("特征向量:", X_scaled)

# 查看特征空间的维数
print("特征空间的维数:", X_scaled.shape[1])
```

在这个示例中，首先生成了一组随机数据，其中包含两个特征。然后使用标准化器（StandardScaler）对特征向量进行了标准化，以便在训练模型时避免梯度下降算法的收敛问题。接下来，我们创建了一个线性回归模型，并使用训练数据集来训练模型。最后使用训练好的模型来预测目标变量，并计算预测误差